

FMU Tabanlı Kalıntı Ayırıştırma ve İkili LSTM Özkodlayıcı Birleşimi ile İşbirlikçi Robotlarda Anomali Tespiti

FMU-Based Residual Decomposition and Dual LSTM Autoencoder Fusion for Anomaly Detection in Collaborative Robots

Cem Süha Yılmaz^{1,4}, Serhat Kahraman^{2,4}, Metin Yılmaz^{2,4}, Hasan Serhan Yavuz¹, Uğur Yayan^{3,4}

Eskişehir Osmangazi Üniversitesi

¹Elektrik-Elektronik Mühendisliği, ²Bilgisayar Mühendisliği, ³Yazılım Mühendisliği

⁴ESOGÜ Akıllı Sistemler Uygulama ve Araştırma Merkezi Otonom Sistemler ve Güvenilirlik Laboratuvarı (ESOGÜ - ASRLab)

Eskişehir, Türkiye

{cshyilmaz, serhatkahraman183, metinyilmaz26}@gmail.com

{hsyavuz, ugur.yayan}@ogu.edu.tr

Özetçe—Bu çalışmada, UR10e işbirlikçi robotunun 1,1 milyon gerçek sensör verisi üzerinde fizik tabanlı ve veri güdümlü iki Uzun-Kısa Süreli Bellek (Long Short-Term Memory, LSTM) özkodlayıcısının skor düzeyinde birleşimini gerçekleştiren bir anomali tespit çerçevesi sunulmaktadır. Kalıntı LSTM özkodlayıcısı, FMU (Functional Mock-up Unit) tabanlı ters dinamik modelden elde edilen 12 kanallı içsel/dışsal kalıntılar üzerinde çalışırken; ham LSTM özkodlayıcısı doğrudan 24 kanallı sensör verisini işlemektedir. Dört sentetik arıza senaryosu (motor kayması, çarpışma, gızıazar hatası, sensör gürültüsü) üzerindeki değerlendirmede, ağırlıklı ortalama birleşimi yüksek başarı oranlarına ulaşmış ve en iyi tekil modele göre F1 değerinde belirgin iyileşme sağlamıştır. Pencere düzeyinde tamamlayıcılık analizi, anomalilerin yaklaşık dörtte birinin yalnızca kalıntı, dörtte birinin yalnızca ham model tarafından tespit edildiğini ortaya koyarak iki temsil uzayının birbirini gerçek anlamda tamamladığını doğrulamıştır.

Anahtar Kelimeler—*anomali tespiti, işbirlikçi robotlar, LSTM özkodlayıcı, skor birleşimi, kalıntı ayırıştırma, tamamlayıcılık analizi*


Abstract—This paper presents a score-level fusion framework combining physics-informed and data-driven Long Short-Term Memory (LSTM) autoencoders for anomaly detection in collaborative robots, evaluated on 1.1 million real sensor samples from a UR10e robot. A residual LSTM autoencoder operates on 12-channel intrinsic/extrinsic residuals from an FMU-based inverse dynamics model, while a raw LSTM autoencoder

processes 24-channel direct sensor data. Evaluation with four synthetic fault types (motor drift, collision, encoder glitch, sensor noise) shows that weighted-average fusion reaches high detection performance and yields a substantial F1 improvement over the best individual model. Window-level complementarity analysis reveals that roughly one-quarter of anomalies are detected only by the residual model and one-quarter only by the raw model, confirming genuine complementarity between the two representations.

Keywords—*anomaly detection, collaborative robots, LSTM autoencoder, score fusion, residual decomposition, complementarity analysis*

I. GİRİŞ

İşbirlikçi robotlar (cobotlar) endüstriyel üretim hatlarında insan çalışanlarla güvenli etkileşim halinde faaliyet göstermekte olup anormalliklerin erken tespiti operasyonel güvenlik açısından kritik önem taşımaktadır [1]. Anomali tespitinde iki temel yaklaşım öne çıkmaktadır: fizik tabanlı kalıntı yöntemleri [2]–[4] ve derin öğrenme tabanlı veri güdümlü yöntemler [5]–[7]. Fizik tabanlı yaklaşımlar, robot dinamik modeli ile ölçülen kuvvetler arasındaki kalıntıyı arıza göstergesi olarak kullanır; ancak genellikle tekil arıza tiplerine odaklanır ve sensör düzeyindeki anomalileri (gürültü, sapma) yakalamakta yetersiz kalır. Veri güdümlü yöntemler ise yüksek boyutlu ham veriden karmaşık desenleri öğrenebilir [8]; ancak fiziksel modelin sağladığı boyut indirgeme ve gürültü filtrelemeden yoksundur. Bu gözlem, her iki yaklaşımın farklı arıza tiplerine karşı tamamlayıcı güçlere sahip olabileceğini düşündürmektedir. Liu ve ark. [9] mekanizma



Şekil 1. Robotik kalite muayene platformu: UR10e robotu, Festo lineer eksen ve muayene şasesi.

kısıtları ile LSTM özkodlayıcısını birleştirmiş; ancak iki ayrı modelin skor birleşimini incelememiştir. Huang ve ark. [10] Dönüştürücü (Transformer) tabanlı dikkat mekanizmasını robot anomali tespitine uygulamakla birlikte fizik tabanlı ön işleme adımı kullanmamıştır. Bu çalışma, UR10e işbirlikçi robotu ile Festo lineer eksenin oluşturduğu artırılmış erişim kapasiteli bir robotik kalite muayene platformu kapsamında yürütülmüştür (bkz. Şekil 1). Hedef uygulama, otomotiv şasesi üzerinde otomatik görsel kalite kontrol işlemlerinin gerçekleştirilmesidir. Bu tür uzun süreli ve insan-robot ortak çalışma alanında yürütülen operasyonlarda; çarpışma, motor bozunması ve sensör arızası gibi anomalilerin erken tespiti hem üretim sürekliliği hem de operatör güvenliği açısından kritik önem taşımaktadır.

Bu çalışmanın temel katkıları: (1) FMU tabanlı ters dinamik model ile kalıntıların içsel ve dışsal bileşenlerine ayrıştırılması; (2) kalıntı ve ham LSTM özkodlayıcı modellerinin skor düzeyinde ağırlıklı ortalama birleşimi; (3) dört sentetik arıza tipiyle modellerin tamamlayıcılığının nicel olarak kanıtlanmasıdır.

II. YÖNTEM

A. Hibrit Kalıntı Ayrıştırma

Ters dinamik model, UR10e Newton-Euler formülasyonunu ($M(q)\ddot{q} + C(q, \dot{q})\dot{q} + g(q)$) [3] FMU formatında paketlemektedir. Toplam kalıntı $\mathbf{r}_{kal,top}$, ölçülen tork ile model tahmini arasındaki farktır:

$$\mathbf{r}_{kal,top}(t) = \boldsymbol{\tau}_{olc}(t) - \hat{\boldsymbol{\tau}}_{model}(t). \quad (1)$$

Dışsal kalıntı, uç noktadaki Kuvvet-Tork Sensörü (KTS) ölçümünün Jacobian aktarımıyla eklem uzayına projeksiyonudur:

$$\mathbf{r}_{kal,dis}(t) = \mathbf{J}(q)^T \mathbf{F}_{KTS}(t). \quad (2)$$

İçsel kalıntı ise toplam ve dışsal bileşenlerin farkı olarak elde edilmektedir:

$$\mathbf{r}_{kal,ic}(t) = \mathbf{r}_{kal,top}(t) - \mathbf{r}_{kal,dis}(t). \quad (3)$$

Bu ayrıştırma, çalışmanın özgün katkısı olup $\mathbf{r}_{kal,ic}$ 'yi içsel arızalara (motor bozunması, gizyazar hatası), $\mathbf{r}_{kal,dis}$ 'yi ise

dışsal etkileşimlere (çarpışma, yük değişimi) duyarlı hale getirmektedir.

B. LSTM Özkodlayıcı Mimarileri

Her iki model, $T=100$ örneklik kayan pencereyi (0,2s) saklı vektöre sıkıştıran simetrik gizyazar-gizçözer mimarisine sahiptir. İki katmanlı LSTM gizyazar girdi dizisini sabit boyutlu saklı vektöre sıkıştırır; gizçözer ise RepeatVector ile T adıma kopyalayıp simetrik LSTM katmanlarıyla yeniden oluşturur. Katmanlar arasında düzenleme amacıyla %15 sönümleme uygulanmıştır. Her iki model yalnızca normal çalışma verisi üzerinde Ortalama Karesel Hata (Mean Squared Error, MSE) kaybıyla [7] eğitilmiş; anomali eşiği doğrulama setindeki yeniden yapılanma hatalarının 97. persentilinde belirlenmiştir. **Kalıntı** model girdisi 12 kanal ($r_{ic,1-6}$, $r_{dis,1-6}$); **Ham** model girdisi 24 kanal (q , $\dot{q}$, τ , KTS, her biri 6 eklem) içermektedir.

C. Skor Düzeyinde Birleşim

İki modelin min-max normalleştirilmiş anomali skorları ağırlıklı ortalama ile birleştirilmektedir:

$$S_{bir}(t) = w_{kal} \bar{S}_{kal}(t) + w_{ham} \bar{S}_{ham}(t). \quad (4)$$

Ağırlıklar $w_{kal} \in [0,1]$ aralığında 0,05 adımla taranarak BestF1 (eşikten bağımsız en yüksek F1) üzerinden optimize edilmiştir. Karşılaştırma için MAX ($\max(\bar{S}_{kal}, \bar{S}_{ham})$) ve OR (her iki modelden birinin eşiği aşması) stratejileri de uygulanmıştır.

D. Sentetik Arıza Enjeksiyonu

Gerçek zemin doğrusu etiketleri bulunmadığından dört sentetik arıza senaryosu tasarlanmıştır. Motor kayması ve gizyazar hatası senaryolarında, UR10e kinematik zincirinde yerçekimine en çok maruz kalan ve hareket aralığı en geniş eklemler olan Eklem 3 (dirsek) ve Eklem 5 (bilek 2) seçilmiştir; bu eklemlerdeki yüksek tork yükü ve hareket genliği ilgili arızaların algılanabilirliğini zorlu koşullarda sınamaktadır. Senaryolar şu şekildedir: (i) **Motor kayması**, Eklem 3 torkuna doğrusal rampa (ham 15 Nm, kalıntı 25 Nm; %30–38 aralığı); (ii) **Çarpışma**, tüm KTS kanallarına Gauss darbe (ham 30 N, kalıntı 40 N; merkez %65, genişlik %4); (iii) **Gizyazar hatası**, Eklem 5 pozisyonuna basamak fonksiyonu (ham 1,5 rad, kalıntı 8 Nm; başlangıç %92); (iv) **Sensör gürültüsü**, tüm KTS kanallarına Gauss gürültü (ham 3,5 N, kalıntı 0,08 Nm; %15–23 aralığı). İlk üç senaryo hem kalıntı hem ham kanalı belirgin biçimde etkilerken sensör gürültüsü, modeller arası tamamlayıcılığı test etmek amacıyla *kasıtlı olarak* yalnızca ham sinyali etkileyecek düşük genlikle ayarlanmıştır. Pencere düzeyinde anomali etiketi, örneklerin en az %10'unun arıza maskesiyle örtüşmesi koşuluyla atanmıştır.

III. DENEYSEL KURULUM

Deneyler, Universal Robots UR10e (12,5 kg yük kapasitesi, 6 eklem) işbirlikçi robotu, Festo lineer eksen ve DELL iş istasyonundan (Core i9-14900, 64 GB RAM, RTX 4000 Ada GPU) oluşan bir robotik çalışma düzeneğinde gerçekleştirilmiştir. Robot, ROS 2 Humble ve MoveIt 2 altyapısı kullanılarak 11 farklı hareket planlama algoritmasıyla çalıştırılmıştır. Veri

Tablo I
VERİ SETİ ÖZELLİKLERİ

Özellik	Değer
Toplam örnek	1.124.432
Örnekleme frekansı	500 Hz
Pencere boyutu / adım	100 / 25 (%75 örtüşme)
Eğitim / doğrulama	35.978 / 8.992
Test penceresi	179.896
Arıza penceresi	14.402 (%8,0)

Tablo II
GENEL PERFORMANS KARŞILAŞTIRMASI

Model	AUC	PR-AUC	BestF1
Kalıntı LSTM Özk.	0,908	0,695	0,692
Ham LSTM Özk.	0,952	0,761	0,698
Bir. A-Ort (0,95/0,05)	0,980	0,905	0,859
Bir. MAX	0,976	0,889	0,824
Bir. OR	0,976	0,889	0,824
Art. Norm Eşik	0,849	0,805	0,707
Isolation Forest	0,688	0,459	0,547
One-Class SVM	0,815	0,816	0,760

seti ayrıntıları Tablo I’de sunulmaktadır. Model eğitimi bir DELL dizüstü bilgisayar (Core i7-13650HX, RTX 4060 GPU) üzerinde tamamlanmıştır.


Her iki LSTM özkodlayıcısı, Adam iyileştiricisi ($\text{lr}=10^{-3}$, $\beta_1=0,9$, $\beta_2=0,999$), 256 yığın boyutu, %15 sönümleme, gradyan kırpması ($\text{max_norm}=1,0$) ve ReduceLROnPlateau çizelgeleyici (faktör = 0,5, sabır = 8) ile eğitilmiştir. Erken durdurma sabır = 25 dönem ile maksimum 300 dönem uygulanmış; kalıntı model 129 dönemde ($\text{val_loss}=0,181$), ham model 87 dönemde ($\text{val_loss}=0,320$) yakınsamıştır. Anomali eşikleri, doğrulama setindeki yeniden yapılanma hatalarının 97. persentilinde belirlenmiştir: kalıntı model $\theta=0,420$, ham model $\theta=0,854$. Temel karşılaştırma yöntemi olarak üç geleksel yaklaşım kullanılmıştır: (i) Kalıntı Norm Eşiği (toplam kalıntı vektörünün L2 normuna sabit eşik), (ii) Isolation Forest (kontaminasyon = 0,08), (iii) Tek Sınıf Destek Vektör Makinesi (One-Class Support Vector Machine, One-Class SVM) (RBF çekirdek, $\nu=0,05$). Bu yöntemler kalıntı öznelikleri üzerinde eğitilmiştir.

IV. SONUÇLAR

A. Genel Performans Karşılaştırması

Kalıntı model 128/32 gizli/saklı boyutla 478.892, Ham model 256/64 boyutla 1.907.032 parametreye sahip olup kalıntı mimari fizik tabanlı ön işlemenin girdi boyutunu düşürmesi sayesinde yaklaşık %75 daha kompakttır. Tablo II, tüm modellerin genel performansını özetlemektedir. Tekil modellerde Ham LSTM özkodlayıcısı daha yüksek Eğri Altındaki Alan (Area Under Curve, AUC) değeri (0,952) elde ederken BestF1 değerleri benzerdir ($\sim 0,70$); AUC tüm eşikler üzerinden ayrıştırma yeteneğini, BestF1 ise tek bir eşikteki kesinlik–geri çağırma dengesini ölçtüğünden, AUC sıralaması seçilen 97. persentil eşisindeki pratik performansı her zaman yansıtmamaktadır. Ağırlıklı ortalama birleşimi ($w_{\text{kal}}=0,95$, $w_{\text{ham}}=0,05$) AUC’yi 0,980’e, Kesinlik-Geri Çağırma AUC (Precision-Recall AUC, PR-AUC) değerini 0,905’e ve BestF1’i 0,859’a yükselterek en iyi tekil modele göre $\Delta\text{BestF1}=+0,161$ iyileşme sağlamış; referans yöntemler arasında en iyi sonucu veren One-Class SVM (0,760) birleşime göre $\Delta=-0,099$ geride kalmıştır.

Şekil 2, tüm modellerin Alıcı İşletim Karakteristiği (Receiver Operating Characteristic, ROC) eğrilerini göstermektedir. Birleşim modelleri sol üst köşeye en yakın konumlanarak yüksek geri çağırma oranlarında bile düşük yanlış pozitif oranı sürdürmektedir.



Şekil 2. Tüm modellerin ROC eğrileri. Birleşim stratejileri ($\text{AUC} \geq 0,976$) tekil modelleri ve referans yöntemleri belirgin biçimde geçmektedir.

B. Arıza Tipine Göre Tamamlayıcılık Analizi

Tablo III, arıza tipine göre BestF1 değerlerini sunmaktadır. **Gizyazar hatası** senaryosunda fizik modeli eklem pozisyon sapmasını büyük kalıntı olarak yansıttığından Kalıntı özkodlayıcısı üstündür (0,986’ya karşı 0,530); **Sensör gürültüsü** senaryosunda ise düşük genlikli KTS gürültüsü ters dinamik modelden süzilemediğinden Kalıntı özkodlayıcısı başarısız kalır (0,272), Ham özkodlayıcısı ise mükemmel sonuç verir (1,000). Çarpışma ve motor kaymasında iki model benzerdir.

Pencere düzeyinde tamamlayıcılık analizi (Şekil 3) 14.402 arıza penceresinin %24,1’inin yalnızca Kalıntı, %25,9’unun yalnızca Ham özkodlayıcı tarafından tespit edildiğini ortaya koymakta; OR-birleşim geri çağırma oranı 0,854 ile tekil modelleri (Kal. 0,595, Ham 0,613) belirgin biçimde geçerek iki temsil uzayının gerçek anlamda tamamlayıcı olduğunu kanıtlamaktadır.

C. Ağırlık Duyarlılık Analizi


Şekil 4, w_{kal} taramasından elde edilen BestF1 eğrisini göstermektedir. $w_{\text{kal}} \in [0,25; 0,95]$ aralığında BestF1 0,84’ün üzerinde sabit kalmakta, en yüksek değer $w_{\text{kal}}=0,95$ ’te (0,859) elde edilmektedir. Geniş kararlı bölge, birleşimin ağırlık seçimine dayanıklı olduğunu; %5’lik Ham katkısının bile tekil Kalıntı modeline göre $\Delta\text{BestF1}=+0,167$ kazanım sağladığını göstermektedir.

V. TARTIŞMA VE SONUÇ

Birleşim kazancının ($\Delta\text{BestF1}=+0,161$) temel kaynağı fizik- veri tamamlayıcılığıdır: ters dinamik model bilinen dinamik bileşenleri ($M(q)\ddot{q}$, $C(q,\dot{q})\dot{q}$, $g(q)$) çıkararak kalıntı uzayında

Tablo III
ARIZA TİPİNE GÖRE BESTF1 KARŞILAŞTIRMASI

Arıza Tipi	Kalıntı	Ham	Birleşim
Motor kayması	0,597	0,605	0,588
Çarpışma	0,916	0,933	0,920
Gizyazar hatası	0,986	0,530	0,977
Sensör gür.	0,272	1,000	0,992




Şekil 3. Dört arıza senaryosunda zamansal anomali tespiti. Kalıntı modelin gizyazar hatasında, Ham modelin sensör gürültüsünde baskın olduğu gözlenmektedir.

sinyal-gürültü oranını artırır ve gizyazar hatası gibi içsel arızaları belirgin biçimde ortaya koyar; ancak aynı filtreleme düşük genlikli sensör gürültüsünü baskımlarken Ham özkodlayıcısı ham veriye doğrudan eriştiğinden bu anomali tipini yakalar. Pencere düzeyinde %24,1 yalnızca-kalıntı ve %25,9 yalnızca-ham tespiti, iki modelin örtüşmeyen hata bölgelerine sahip olduğunu doğrular. PR-AUC'deki kazanım (0,905'e karşı 0,761; $\Delta=+0,144$), kesinlik-geri çağırma eğrisinin sınıf dağılımına duyarlılığı nedeniyle %8 oranlı dengesiz arıza veri setinde özellikle anlamlıdır. En iyi ağırlığın $w_{kal}=0,95$ olması, kalıntı modelin baskın katkısı sağladığını; yalnızca %5'lik Ham katkısının ise sensör gürültüsü gibi kör noktaları kapatıp BestF1'de 0,167 kazanım yarattığını göstermektedir. $w_{kal} \in [0,25; 0,95]$ kararlı bölgesi, birleşimin hiperparametre hassasiyetinden bağımsız olarak güvenilir sonuç ürettiğini ortaya koymaktadır. Referans yöntemler arasında Kalıntı Norm Eşiği'nin (0,707) LSTM modellerine yakın performans göstermesi, fizik tabanlı ön işlemenin başlı başına güçlü bir gösterge sağladığını doğrulamakta; Isolation Forest'ın (0,547) ise yüksek boyutlu zaman serisinde yetersiz kaldığı görülmektedir. Toplam çıkarım gecikmesi (FMU hesabı dâhil) GPU üzerinde 10 ms'nin altında kalmakta, gerçek zamanlı izleme için uygun olmaktadır.

Kısıtlamalar: Tek robot (UR10e) ve tek görev profili (otomotiv kalite muayene) genelleme iddialarını sınırlamakta; farklı robot tipleri (ör. UR5e, Franka Emika) üzerinde doğrulama yapılması gerekmektedir. Sentetik arızalar gerçek arıza dinamiklerinin tüm karmaşıklığını yansıtamayabilir. Motor kayması senaryosunda birleşim marjinal düşüş göstermiştir ($\Delta=-0,017$); bu durum, her iki model benzer performans gösterdiğinde ağırlıklı ortalamanın sinyali hafifçe seyreltebileceğini işaret etmektedir.

Gelecek çalışmalar: (i) Çarpışma senaryosunda KTS kanallarına eşit dağıtılan darbe yerine gerçek temas noktasından



Şekil 4. Birleşim ağırlık duyarlılığı: $w_{kal} \in [0,25; 0,95]$ aralığında BestF1 $> 0,84$.

Jacobian aracılığıyla yayılan darbe modelinin uygulanması; (ii) Dönüştürücü tabanlı dikkat mekanizmalarının [10] kalıntı uzayına uygulanması; (iii) sistemin UR10e ile eş zamanlı çevrimiçi çalıştırılması başlıca yönlerdir. Sonuç olarak, fizik tabanlı kalıntı ve veri güdümlü ham LSTM özkodlayıcılarının skor düzeyinde birleşimi, tekil modellere ve geleneksel referans yöntemlere göre anlamlı üstünlük sağlamakta; tamamlamıcılık analizi bu kazanımın modellerin farklı arıza tiplerine duyarlılıklarındaki asimetriden kaynaklandığını kanıtlamaktadır.

BİLGİLENDİRME

Proje, KDT Ortak Girişimi (101140216) (KDT JU) ve üyeleri tarafından desteklenmektedir. Bu destek, Vinnova (İsveç), Österreichische Forschungsförderungsgesellschaft mbH – FFG (Avusturya), Business Finland (Finlandiya), Üniversiteler ve Araştırma Bakanlığı (İtalya), FCT (Portekiz) ve TÜBİTAK (124N448) (Türkiye) tarafından sağlanan ek finansmanı da içermektedir.

KAYNAKLAR

- [1] L. Correia, J. C. Goos, P. Klein, T. Bäck, and A. V. Kononova, "Online model-based anomaly detection in multivariate time series: Taxonomy, survey, research challenges and future directions," *Engineering Applications of Artificial Intelligence*, vol. 138, p. 109323, 2024.
- [2] K. Katsampiris-Salgado *et al.*, "Collision detection for collaborative assembly operations on high-payload robots," *Robotics and Computer-Integrated Manufacturing*, vol. 87, p. 102708, 2024.
- [3] W. Li, Y. Han, and Z. Xiong, "Collision detection of robots based on a force/torque sensor at the bedplate," *IEEE Transactions on Industrial Electronics*, vol. 67, no. 12, pp. 12 440–12 449, 2020.
- [4] T. Zhang, Y. Chen, and Y. Zou, "Robot collision detection based on external torque observer," *Journal of South China University of Technology*, vol. 52, no. 3, pp. 84–92, 2024.
- [5] Z. Z. Darban, G. I. Webb, S. Pan, C. C. Aggarwal, and M. Salehi, "Deep learning for time series anomaly detection: A survey," *ACM Computing Surveys*, vol. 57, no. 1, pp. 1–42, 2024.
- [6] P. Malhotra, L. Vig, G. Shroff, and P. Agarwal, "Long short term memory networks for anomaly detection in time series," in *Proceedings of the European Symposium on Artificial Neural Networks (ESANN)*, 2015, pp. 89–94.
- [7] P. Malhotra, A. Ramakrishnan, G. Anand, L. Vig, P. Agarwal, and G. Shroff, "LSTM-based encoder-decoder for multi-sensor anomaly detection," *arXiv preprint arXiv:1607.00148*, 2016.
- [8] D. Park, Y. Hoshi, and C. C. Kemp, "A multimodal anomaly detector for robot-assisted feeding using an LSTM-based variational autoencoder," *IEEE Robotics and Automation Letters*, vol. 3, no. 3, pp. 1544–1551, 2018.
- [9] K. Liu *et al.*, "Anomaly detection in multidimensional time series for water injection pump operations based on LSTM-AE and mechanism constraints," *Scientific Reports*, vol. 15, 2025.
- [10] X. Huang, N. Chen, Z. Deng, and S. Huang, "Multivariate time series anomaly detection via dynamic graph attention network and informer," *Applied Intelligence*, vol. 54, pp. 7636–7658, 2024.